

# Klassificering i maskininlärning

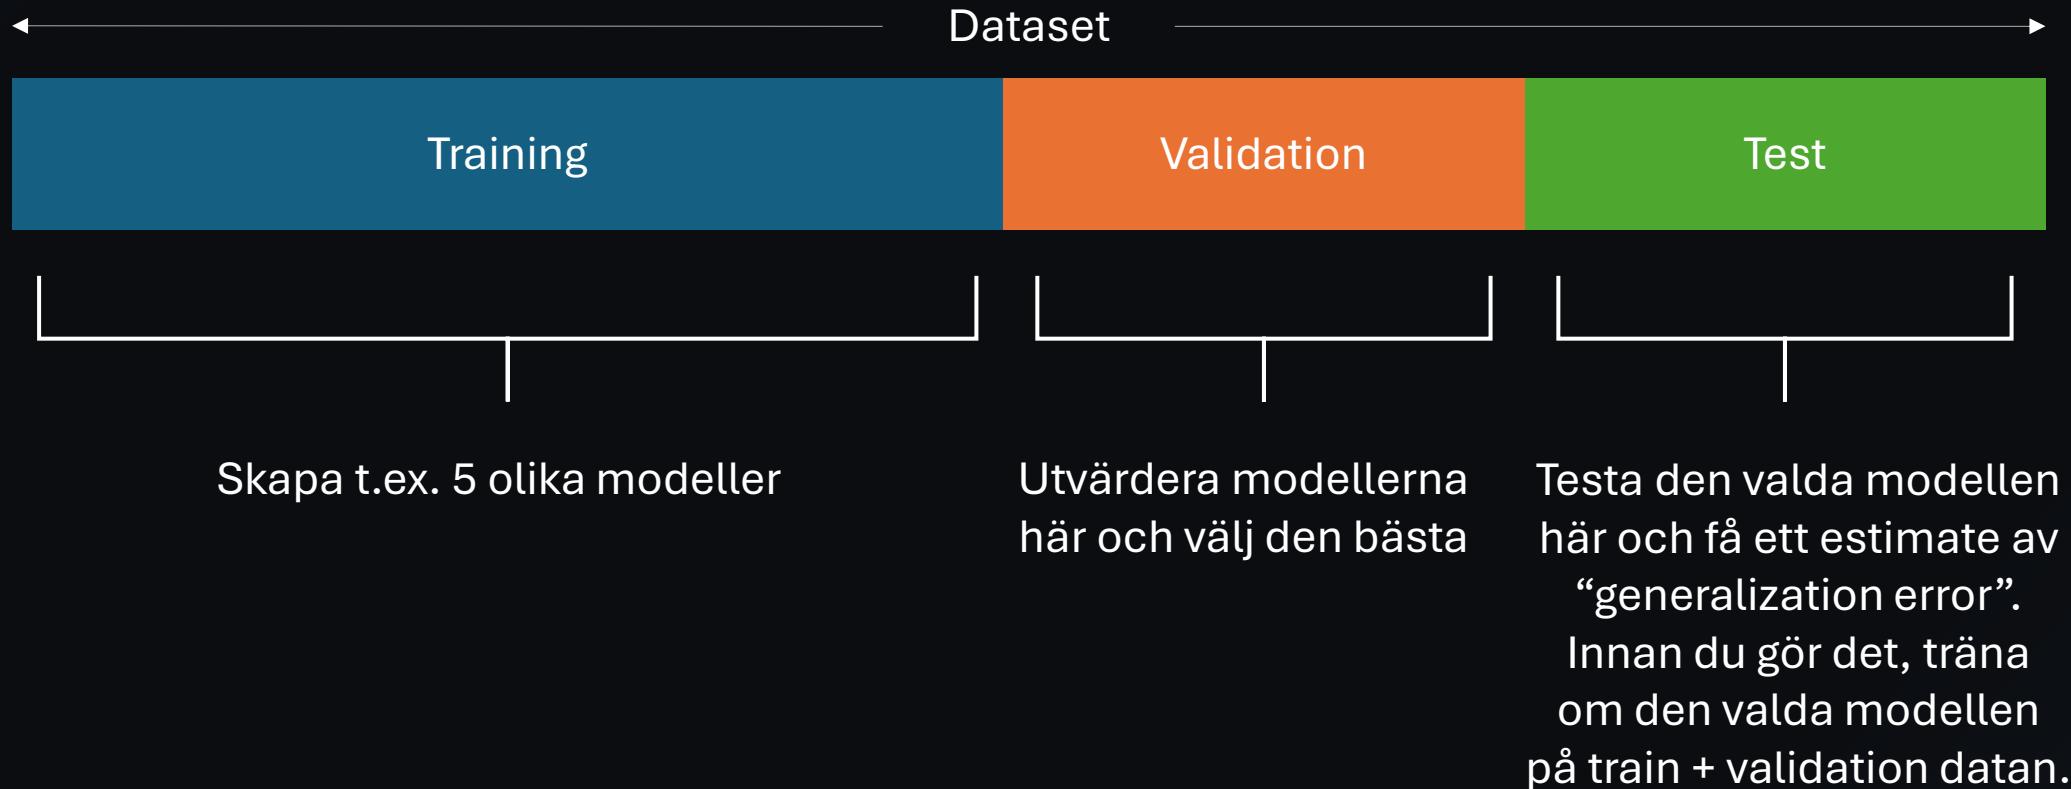
# Klassificering vs Regression

- Regression: förutsäger ett tal (kontinuerligt)  
Ex: pris, temperatur, inkomst
- Klassificering: förutsäger en klass/kategori  
Ex: spam/inte spam, sjuk/frisk, 0-9 på en bild
- Ofta: modellen räknar en score/sannolikhet → vi gör ett beslut

# Vad kommer in och vad kommer ut?

- Input: features X (t.ex. ålder, köp, klick...)
- Output: label y (klass)
- Modellen lär sig ett mönster:  $X \rightarrow y$
- Viktigt: modellen gissar på nya exemplen den aldrig sett

# Train / Validation / Test



Viktigt: gör all preprocessing (t.ex. scaling) inuti pipeline efter split → annars risk för data leakage.

# Score

- Många modeller ger score/probability
- Ex:  $p(\text{klass}=1) = 0.83$
- För att få “0 eller 1” behövs ett beslut: threshold

# Threshold

- Beslutregel:
  - om  $p \geq 0.5 \rightarrow$  klass 1
  - annars  $\rightarrow$  klass 0
- Men: threshold kan vara 0.2, 0.8, ...
- Valet beror på: vilket fel är värst?

# Confusion Matrix

- **TP:** Modellen sa positivt och det var positivt
  - True/False = hade modellen rätt?
  - Positive/Negative = vad sa modellen?
- **TN:** Modellen sa negativ och det var negativt
- **FP:** Modellen sa positiv men det var egentligen negativt – alltså ett falskt alarm
- **FN:** Modellen sa negativ men det var egentligen positivt – alltså en miss

		Predicted	
		Negative (N) -	Positive (P) +
Actual	Negative -	True Negatives (TN)	False Positives (FP)
	Positive +	False Negatives (FN)	True Positives (TP)

# Vilket fel är värst?

- Ex 1: Sjukdomsscreening
  - FN kan vara farligt → vill fånga många sjuka
- Ex 2: Spamfilter
  - FP kan vara irriterande → vill inte stoppa viktiga mail
- Alltså: metric-val beror på mål

# Accuracy (andel rätt)

- Accuracy =  $(TP + TN) / (\text{alla})$
- Bra när:
  - Klasserna är ungefär balanserade
  - FP och FN har liknande kostnad
- Risk när:
  - Obalans
  - Olika kostnader

# Varför accuracy kan lura

- Att utvärdera klassifieringsmodeller är inte alltid lätt
- Dataset: 1% positiva, 99% negativa
- Modell som alltid gissar “negativ” får 99% accuracy
- Men den hittar 0 av de positiva

# Obalans och stratifiering

- Obalans = en klass är mycket vanligare
- Se upp: accuracy kan bli missvisande
- Vi vill ofta behålla klassfördelningen i train/test (stratifera)

# Baseline

- Baseline = enkel referens
- Ex:
  - Gissa alltid majoritetsklass
  - Eller slumpa efter klassfördelning
- Om vår modell inte slår baseline: då har vi problem

# Precision

- Precision =  $\frac{TP}{TP+FP}$
- Fråga: ”När modellen säger positiv – hur ofta har den rätt?”
- Bra när falska larm (FP) är dyra  
Ex: spamfilter som råkar blockera viktiga mejl

		Predicted	
		Negative (N) -	Positive (P) +
Actual	Negative -	True Negatives (TN)	False Positives (FP)
	Positive +	False Negatives (FN)	True Positives (TP)

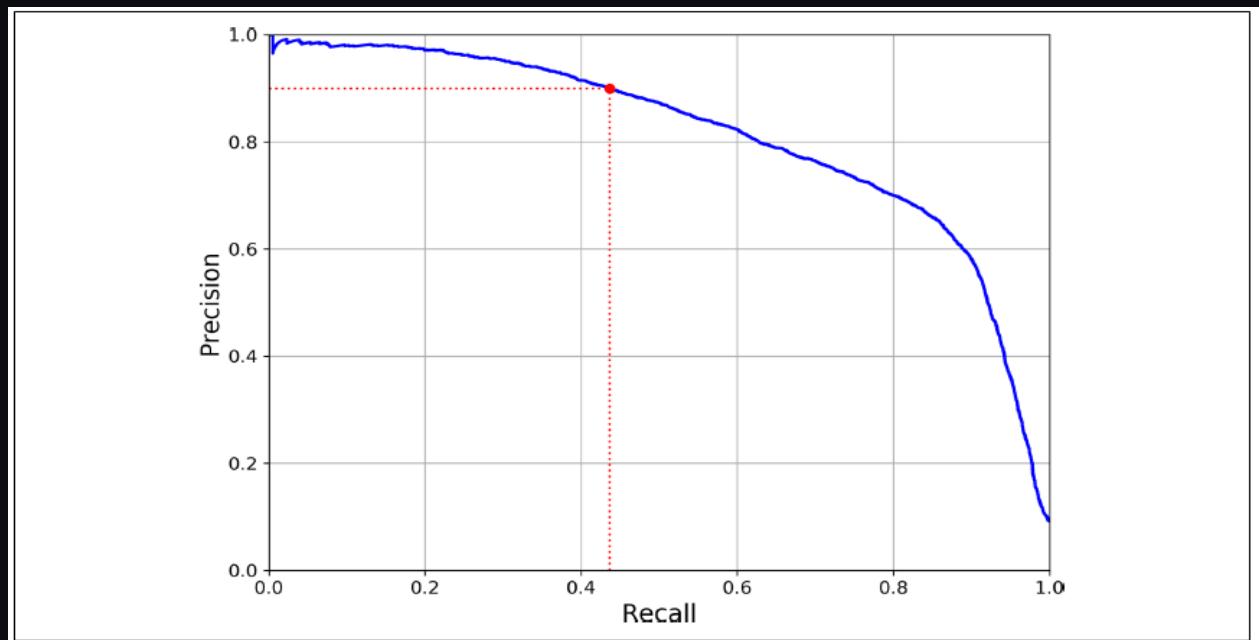
# Recall

- $\text{Recall} = \frac{TP}{TP+FN}$
- Fråga: "Av alla verkliga positiva – hur många hittar vi?"
- Bra när missar (FN) är dyra  
Ex: sjukdom, bedrägeri, säkerhet

		Predicted	
		Negative (N) -	Positive (P) +
Actual	Negative -	True Negatives (TN)	False Positives (FP)
	Positive +	False Negatives (FN)	True Positives (TP)

# Precision / Recall trade-off

- Lägre threshold = fler positiva prediktioner
  - Recall  $\uparrow$  (färre missar)
  - Precision  $\downarrow$  (fler falska alarm)
- Högre threshold = färre positiva prediktioner
  - Precision  $\uparrow$
  - Recall  $\downarrow$
- Ingen magisk lösning: välj utifrån målet



*Ibland kan båda förbättras samtidigt när modellen blir bättre – men principen att det finns en trade-off gäller nästan alltid i praktiken.*

# F1 Score (balansmått)

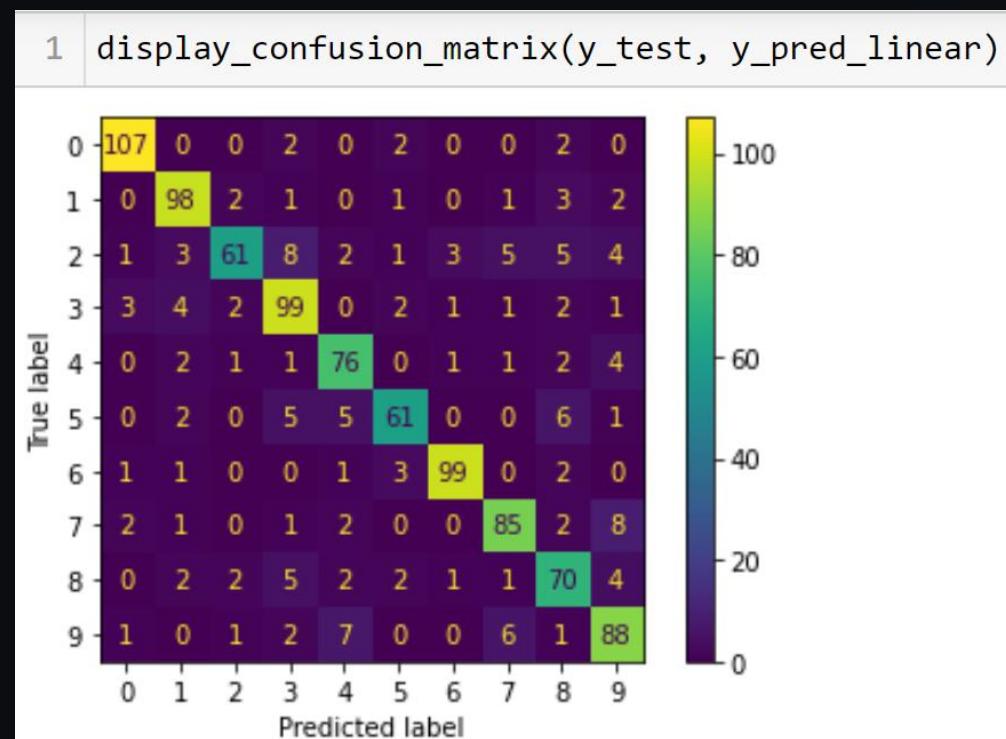
$$F_1 \text{ Score} = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}}$$

- F1 kombinerar precision och recall
- Hög F1 kräver att båda är rimligt höga
- Användbart när:
  - klasser är obalanserade och du vill ha balans
  - Man vill ha en sammanfattande siffra
- Men: man ska fortfarande titta på precision & recall var för sig

Precision	Recall	F_1 Score
1	1	1
1	0,01	0,019802
0,01	1	0,019802
0,9	0,4	0,553846
0,6	0,7	0,646154
0,9	0,1	0,18
0,6	0,4	0,48

# Multi-class: flera klasser

- Ex: siffror 0 – 9
- Confusion matrix blir större (10x10)
- Metrics kan beräknas som:
  - macro (alla klasser lika viktiga)
  - micro (räkna totalt)
  - weighted (viktat efter klass-storlek)



# Receiver Operating Characteristic (ROC)

$$TPR \text{ (Recall)} = \frac{TP}{P} = \frac{TP}{TP + FN}$$

Fråga: Vad besvarar TPR?

Svar: Andelen av den positiva klassen som vi predikterar korrekt.

$$FPR = \frac{FP}{N} = \frac{FP}{FP + TN}$$

Fråga: Vad besvarar FPR?

Svar: Andelen av den negativa klassen som vi felaktigt predikterar som positiv.

# ROC-kurvan

- ROC: True Positive Rate vs False Positive Rate
- Varje punkt = en threshold
- AUC = area under curve
- 1.0 = perfekt
- 0.5 = slump

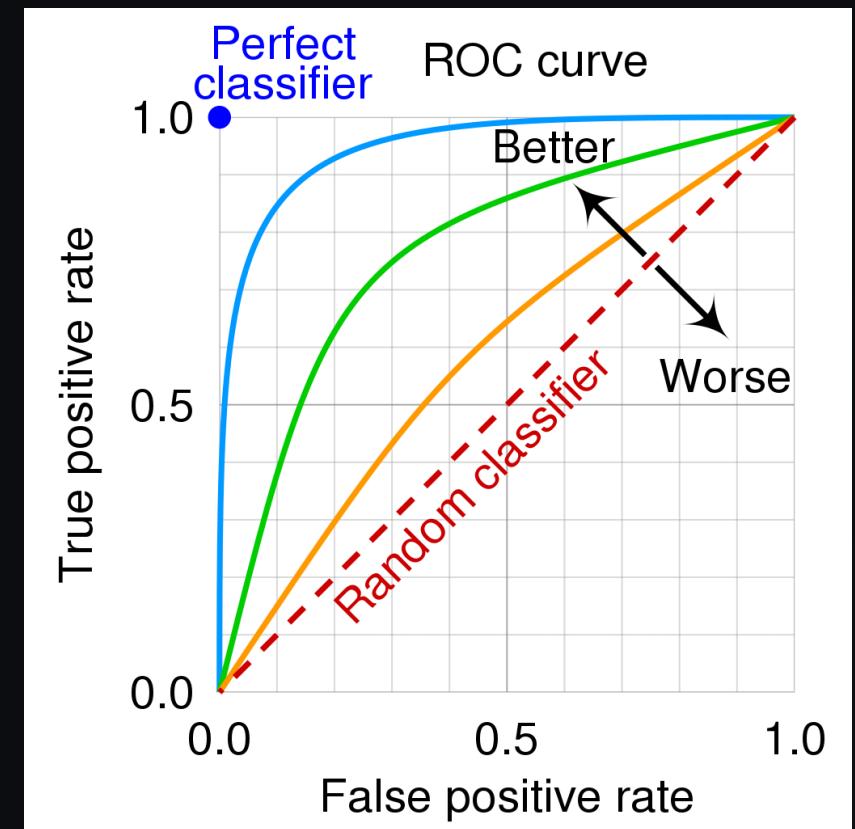


Bild tagen från: [https://en.wikipedia.org/wiki/Receiver\\_operating\\_characteristic](https://en.wikipedia.org/wiki/Receiver_operating_characteristic)

# När ROC/AUC är bra

- ROC/AUC bra för:
  - Jämföra modeller över många thresholds
  - Få en stabil helhetsbild
- Kan bli mindre intuitivt vid stark obalans
- Då kan PR-kurva ibland vara mer informativ

Vi kommer primärt använda confusion matrix + precision/recall/F1 i kursen. ROC/AUC är ett extra verktyg.

# Klassificering i maskininlärning

Joakim Lindh