


Modellfamiljer för klassificering

Vad betyder Modellfamilj?

- Olika modeller = olika antaganden om mönster
- Tradeoffs:
 - Prestanda
 - Tolkbarhet
 - Robusthet
 - Hastighet
- Samma data → olika resultat




Jämföra modeller

1. Vilka mönster kan modellen fånga?
2. Vad kräver den i preprocessing?
3. Hur hanterar den överanpassning?
4. Hur lätt är den att förklara?

Score → Beslut


- Modellen output är ofta ett score / en sannolikhet
- Beslut kräver en regel: threshold eller top-X



Logistic Regression



Logistic Regression

- Linjär modell för klassificering
- Stabil
- Ger ofta bra sannolikheter




Vad betyder ”linjär” i praktiken?

- Rak gräns: linje/plan/hyperplan
- Begränsning: kan missa ”krokiga” mönster utan bättre features




Regularisering

- Regularisering = ”håll modellen enkel”
- Moverkar överanpassning
- Scikit-learn: mindre C → mer regularisering



Preprocessing


- Skalning är ofta viktigt
- Kategorier behöver kodas (t.ex. one-hot)
- Missing values kräver en strategi



Decision Trees

Decision Tree: intuition

- Bygger regler: "om $X > t$ "
- Fångar icke-linjära mönster
- Kan vara intuitiv att förstå



Styrkor och svagheter hos träd



- Styrkor:
 - Fångar komplexa samband
 - Ofta ingen scaling
 - Intuitiv logik
- Svagheter:
 - Överanpassar lätt
 - Instabilt: små dataändringar → nytt träd

Overfittning i träd

- Djupare träd → fler och mer detaljerade regler
- För små blad → “specialregler”
- Stort gap mellan train och test = varningssignal

Trädets reglage

- max_depth
- min_samples_leaf
- min_samples_split




Preprocessing för träd

- Scaling behövs oftast inte
- Kategorier/missing kräver fortfarande strategi
- Viktigt med konsekvens (pipeline)

Ensemble learning & Random Forest

Ensemble learning: grundidén

- Kombinera flera modeller
- Målet: stabilare och ofta bättre generalisering
- ”Wisdom of the crowd”





Hard vs Soft voting

- Hard voting: majoritet på klass (0/1)
- Soft voting: medel av sannolikheter → beslut
- Soft kräver att modeller kan ge probabilities

- Hard: $[1, 0, 1] \rightarrow 1$
- Soft: $[0.6, 0.4, 0.9] \rightarrow 0.63 \rightarrow 1$

Bagging vs Boosting

- Bagging: många modeller parallellt på olika sample → vote/medel
 - Pasting: sampling utan återläggning
- Boosting: modeller i serie, nästa fokuserar på tidigare fel



Random Forest



- Ensemble av beslutsträd
- Bagging + slump i features
- Röstar → prediktion

Varför Random Forest ofta är stark

- Enskilt träd: instabilt, överanpassa lätt
- Många träd: stabilare, generaliseras bättre
- Oftast behövs ingen scaling

RF: viktigaste hyperparametrar

- n_estimators
- max_depth
- min_samples_leaf
- max_features



Från score till beslut

Threshold & top-X

Modellen är inte hela systemet

- Modell → score
- Beslut → regel/policy
- Fel har konsekvenser

Data → model → score → decision

Confusion Matrix


- **TP:** Modellen sa positivt och det var positivt
 - True/False = hade modellen rätt?
 - Positive/Negative = vad sa modellen?
- **TN:** Modellen sa negativ och det var negativt
- **FP:** Modellen sa positiv men det var egentligen negativt – alltså ett falskt alarm
- **FN:** Modellen sa negativ men det var egentligen positivt – alltså en miss

		Predicted	
		Negative (N) -	Positive (P) +
Actual	Negative -	True Negatives (TN)	False Positives (FP)
	Positive +	False Negatives (FN)	True Positives (TP)

Threshold

flytta gränsen, ändra beteendet

- Regel: positiv om $\text{proba} \geq t$
- Lägre $t \rightarrow$ fler flaggas (ofta fler TP men också fler FP)
- Högre $t \rightarrow$ färre flaggas (ofta färre FP men också fler FN)



Top-X

prioritera de högst rankade

- Flagga de X% högst score
- Styr volym
- Fokus: kvalitet i toppen

Probability
0.87
0.82
0.73
0.55
0.54
0.51
0.48
0.42

Modellfamiljer för klassificering

Joakim Lindh